

120 工位 AI 行为检测系统 — 架构方案对比

方案 A 集中式 GPU 集群 | 方案 B 边缘推理 + 中心汇聚

编制日期: 2026-06-01 | 版本: V1.0 | 共同前提: 120 路 1080p • 25FPS • 双模型常驻 (主检测+指关节) • 全程录像 6 个月

一、两种架构总览

方案 A: 集中式 GPU 集群 (推理放机房)

工位1..120 [相机] —压缩流—> 机房集群

4× 推理机 (32× L40S)	集中跑 120 路双模型
1× 数据库/调度机	结果入库 + 大屏 + 分流
3× 存储机 (~2.9PB)	录像存档

方案 B: 边缘推理 + 中心汇聚 (推理放工位)

工位1 [相机]→[算力机]——
工位2 [相机]→[算力机]—— 每台本地跑双模型(主检测+指关节)
... —> [中心服务器 ×1] — 收 120 路视频流(录像)
工位120[相机]→[算力机]—— — 收检测结果(入库)
— 大屏/报表/接口
— 挂存储盘柜(~2.9PB)

二、配置清单对比

部件	方案 A 集中式 GPU 集群	方案 B 边缘 + 中心
推理算力	4 台推理服务器, 共 32× NVIDIA L40S 48GB	120 台边缘算力机 (Jetson Orin NX 16GB), 中心不推理
中心/汇聚	1 台数据库+调度服务器	1 台中心服务器 (收流+入库+大屏, 可选 1× L4 供大屏解码)
存储	3 台存储服务器 (Ceph 8+3, ~2.9PB 可用)	中心挂 JBOD 盘柜 (~2.9PB 可用)
服务器/盒子数	8 台服务器	120 边缘盒 + 1 中心 + 盘柜
机房功耗	~30 kW (需精密空调+专用配电)	中心 ~3-5 kW; 算力机功耗分散到各工位
网络入流	~1.3 Gbps	~0.72 Gbps (结果+录像流汇中心)

三、成本粗估对比 (人民币, 市场大致价, 未含税/折扣)

口径	方案 A 集中式 GPU 集群	方案 B 边缘 + 中心
纯硬件	~380 ~ 450 万	~150 ~ 180 万
+ 软件开发 + 实施 (不含相机/机房)	~520 ~ 700 万	~250 ~ 350 万
中心 GPU 数量	32× L40S	0 ~ 1 张 (仅大屏)
软件改造量	大 (需做分布式推理调度)	小 (边缘≈现产品瘦身, 中心做汇聚)

方案 B 便宜的根本原因: 边缘加速器按单路成本远低于"切数据中心大卡", 且中心免掉 32 张 L40S (约省 200 万)。两方案存储成本相近 (录像量一致)。

四、优劣对照

维度	方案 A 集中式 GPU 集群	方案 B 边缘 + 中心
----	-----------------	--------------

成本	高	低近一半
软件改造	大	小
故障影响面	一台推理机坏影响 30 路	一台算力机坏只影响 1 路
现场部署	机房集中，好管	120 个盒子要装、供电、布网、维护
散热/功耗	~30kW 集中散热压力	分散，无机房级散热
模型升级	中心统一升级	需远程批量推送到 120 台

五、选型建议

- **优先推荐方案 B（边缘 + 中心）**：成本低近一半、软件改造小、单点故障影响面小，且与现有产品形态一致，落地风险最低。
- 方案 B 可进一步优化：用稍强算力机（AGX Orin 或 x86+A2000）**一台带 4 个工位**，盒子从 120 台降到约 30 台，硬件再省、维护点减少 4 倍（前提：工位物理距离允许就近共享）。
- 选方案 A 的唯一理由：现场无法在工位侧部署设备、必须全部集中机房管理；但需接受更高成本与更大软件改造量。

六、关键前提（共同适用）

- 相机须为压缩 IP 相机（H.264/H.265，1080p）；非压缩 GigE Vision 相机不适用。
- 两方案均需配套服务端软件（方案 B 改造量显著更小）。
- 录像按 1080p25 约 6Mbps 测算，存储 ~2.9PB 可用（含 30% 余量）；码率更高时按比例上浮。
- 成本为容量规划测算量级，最终以现场参数与正式询价为准；相机、机房改造可能另计。

本对比方案为架构与容量测算结果，供选型参考。