

120 工位 AI 行为检测集中式服务器集群

配置方案（精简 8 台版 · 25FPS · 指关节模型常驻）

编制日期：2026-06-01 | 版本：V1.0 | 适用：1080p / 全程录像 / 6 个月留存

一、方案参数（已锁定）

项目	规格
工位 / 相机	120 路 1080p IP 相机（单码流，录像与分析共用，须为 H.264/H.265 压缩相机）
录像	1080p / H.264 / 25fps，约 6 Mbps；全程 24×7 连续录 + 每周期片段；保存 6 个月
推理	1080p 输入；稳定 25 FPS（保底，只高不低）；每路双模型常驻每帧（主检测 + 指关节）
资源余量	各环节预留 30%，常态负载 ≤ 70%

二、硬件采购清单

序	设备	关键配置	数量	单价	小计
1	推理 / 接入服务器	8× NVIDIA L40S 48GB；2× AMD EPYC 9454(48C)；512GB DDR5 ECC；2×960GB NVMe(系统镜像)+4×3.84TB NVMe(写缓冲)；双口 25GbE	4		
2	数据库 + 调度服务器 (二合一)	2× EPYC(64C)；1TB DDR5 ECC；8×7.68TB NVMe RAID10；双口 25GbE。承载 PostgreSQL+TimescaleDB 主库 + 调度/API/大屏软件	1		
3	存储服务器	60×22TB 企业 HDD + 2×7.68TB NVMe 缓存；双口 25GbE。Ceph 纠删码 8+3	3		
4	100GbE 骨干交换机	32 口 100GbE，冗余对	2		
5	25GbE 接入交换机	48 口 25GbE	2		
6	相机接入交换机	48 口千兆 + 25GbE 上联	3		
7	机柜 + PDU + 理线	标准 42U 机柜 + 双路 PDU	2		
8	UPS 不间断电源 + 散热	按 ~30kW 配置	1 套		

三、容量与总量

服务器总数	8 台（4 推理 + 1 库/调度 + 3 存储）	GPU 总数	32× NVIDIA L40S 48GB
单台推理承载	30 路（常态 ~65% 负载）	存储可用容量	~2.9 PB（裸 ~3.96PB）
网络入流	~1.3 Gbps	功耗	~30 kW
机柜	~2 个标准机柜	留存周期	6 个月全程录像

存储测算（1080p25 H.264 全录）：单路 ~63GB/天 → 120 路 × 180 天 ≈ 1.3PB → 含周期片段 ≈ 1.63PB → 含 30% 余量需求 ≈ 2.1PB → 配置可用 ~2.9PB（满足）。

四、单点风险与兜底措施

精简项	风险	必须的兜底措施
推理机无热备	坏一台 → 该 30 路降级，其余 3 台升至 ~87% 负载，有跌破 25FPS 风险	软件支持故障自动重分流到其余 3 台；备件库常备 1 台整机或 8 张 GPU，坏件 4 小时内更换

调度做成软件（跑在库机上）	承载它的机器为单点，该机故障 → 大屏/分流中断（检测与录像可继续）	进程看门狗自动拉起；配置与状态落盘，重启秒级恢复
数据库仅主库	库机/硬盘损坏 → 历史查询中断，故障期检测结果可能写不进库	本地 RAID10（已含）+ 每日自动备份至存储集群 + 日志归档

五、稳定性保障（7×24 设计）

- 单路独立隔离 + 看门狗自动重启：单路异常不连累其余 119 路。
- 全资源常态负载 ≤ 70%：保证检测帧率稳压在 25FPS 以上、绝不低于 25。
- 存储纠删码 8+3：同时损坏 3 块硬盘不丢失数据。
- 写入分层：本地 NVMe 缓冲 → 异步刷入存储集群，抗 120 路并发写。
- 三网物理隔离：相机网 / 存储网 / 业务网分离，互不干扰。

六、关键前提（须向客户说明）

- 相机须为压缩 IP 相机（H.264/H.265，1080p）；非压缩 GigE Vision 相机不适用本方案。
- 本方案为服务端集中式架构，需配套服务端软件开发（与现有单机桌面版不同，须立项）。
- 录像按 1080p25 约 6Mbps 测算；画面运动剧烈、码率更高时，存储按比例上浮（已预留 30% 余量缓冲）。
- 本方案为"预算优先"定位：正常生产满足 120 路 25FPS；单台故障窗口期相关工位会降级，靠备件快速更换恢复。

本配置方案为容量规划测算结果，最终以现场相机参数、码率与实测模型性能为准。